

— Cloud AI & industrialisation

Introduction



IA dans le cloud

Objectifs

- Apprendre à déployer l'IA
- Avoir des notions de bases de pattern/applications incluant l'IA, et les bons principes.
- Découvrir certains des fournisseurs et services Clouds.
- Se familiariser avec docker, kubernetes, des serveur d'inference, de l'api, du serveur/client, mlops/ci-cd....

1. Définitions et concepts généraux

LA MISE EN ŒUVRE DE L'IA

Ce n'est pas un problème facile



Techniques

- ✓ Quelle IA ?
- ✓ Quelles données ?
- ✓ Quelle Infra ?
- ✓ Quelle échelle ?
- ✓ Quelle protection ?



Organisationnels

- ✓ Quelle responsable/gouvernance ?
- ✓ Quelle stratégie ?
- ✓ Quel accompagnement des métiers ?
- ✓ Quelle formation ?
- ✓ Quelle protection ?



Ethiques et juridiques

- ✓ RGPD ?
- ✓ AI Act ?
- ✓ Quels biais ?
- ✓ Quels impacts ?



économiques

- ✓ Quel investissement ?
- ✓ Quel ROI visé ?
- ✓ Quelle temporalité ?

LA MISE EN ŒUVRE DE L'IA

Ce n'est pas un problème facile



Techniques

- ✓ Quelle IA ?
- ✓ Quelles données ?
- ✓ Quelle Infra ?
- ✓ Quelle échelle ?
- ✓ Quelle protection ?



Organisationnels

- ✓ Quelle responsable/gouvernance ?
- ✓ Quelle stratégie ?
- ✓ Quel accompagnement des métiers ?
- ✓ Quelle formation ?
- ✓ Quelle protection ?



Ethiques et juridiques

- ✓ RGPD ?
- ✓ AI Act ?
- ✓ Quels biais ?
- ✓ Quels impacts ?



économiques

- ✓ Quel investissement ?
- ✓ Quel ROI visé ?
- ✓ Quelle temporalité ?

- Vous n'avez heureusement **pas à être expert de l'ensemble de ces sujets !**
- Mais il faut un **minimum de culture générale et connaissance pour pouvoir discuter efficacement avec les experts de chaque partie !**
 - **Il faut savoir que le problème existe pour penser à discuter avec un expert du problème !**

IA dans le cloud

Définitions

Utilisation de technologies d'IA dans un environnement de calcul cloud. On parle aussi de « cloud computing ». Cette approche permet **de déporter** tout ou une partie des tâches essentielles au bon fonctionnement d'une application : stockage, calcul, sécurité, scalabilité, réplication, etc...

→ **Attention** : Cloud ne veut pas dire forcément dire externalisation de l'entreprise

IA dans le cloud

Les différents types de clouds

1- Les clouds privés :

- Hébergement sur site (on-premises)
 - Sur un site appartenant à l'entreprise
 - Choix que l'on a fait à Scalian pour Thoth
- Sur serveur externe (hosted):
 - L'entreprise loue les serveurs d'un hébergeur.
 - Définition majoritaire : Quand vous êtes le seul à partager votre hardware.
 - BareMetal : Location du matériel sur un site n'appartenant pas à l'entreprise.
 - Souvent (ex: OVH hosted private) : couche de virtualisation avec.

➔ La limite entre hosted private cloud et public peut être mince et différente suivant qui parle.

IA dans le cloud


Les différents types de clouds

2- Les clouds publics :

- IaaS : Infrastructure as a service
 - Vous louez des instances de machines virtuelles, des espaces de stockages, de la bande passante réseau
- PaaS : Plateforme as a service
 - Vous gérez les applications et données.
 - Vous ne gérez pas l'OS, ou l'exécution des applications.
 - Vous avez souvent le choix parmi une stack techniques d'applications disponibles sur la plateforme
 - Ex : Openshift. Vous fournissez l'IDE, les environnements ou containers avec les applications installées, des bases de données, des pipelines pour déployer les applications.
- SaaS : software as a service.
 - Vous utilisez des applications maintenues par le cloud provider.
 - Google (Gmail, google drive, etc), Microsoft (outlook, onedrive, sharepoint, ...).

IA dans le cloud


Résumé



IA dans le cloud

Ex Thoth

On premise



Thoth

front, back, serveur d'inference

Mongodb, filesystem (logs)

Triton, vunicorn

Docker

RedHat

Aucun : baremetal

Achat, DSI.

DSI

Salle serveur Scalian

IA dans le cloud

Propriétés (généralement attendues) du cloud

- Pouvez vous me donner des propriétés qui vous ferez utiliser le cloud ?

IA dans le cloud

Propriétés (généralement attendues) du cloud

Flexibilité

- Ressources à la demande ou dynamiques
- Diversité des ressources disponibles (hardware, technos, ...)
- Mise en commun des ressources (pooling)
- Accès global, collaboratif

Scalabilité

- Ressources à la demande
- Technologies permettant la scalabilité à disposition

Suivant le type de cloud, fourni ou pas !

Facilité

- Technologies, services existant déjà développés
- Diminuer ou faciliter le temps de développement ou déploiement

Sécurité

- Réplication sur différents sites des données
- Couche de sécurité
- Contrôle et mesure de l'utilisation

IA dans le cloud

Quand, qui et pourquoi?

Quand ?

- Création, déploiement, intégration ou utilisation d'applications
 - Environnements/platformes de développements clouds
 - Ex: Onyxia pour les ds
 - Outils/platformes pour déployer/industrialiser
 - Ex: Kubernetes
 - Intégration
 - Ex: API clouds
 - Utilisation
 - Ex: Microsoft Teams, Onedrive

Qui?

- Potentiellement tout le monde
 - Grands groupes
 - Startup
 - Pme
 - Individus
 - ...

Pourquoi?

- Pour une ou plusieurs des propriétés slides précédentes
- Rentabilité et économies (?)

IA dans le cloud

Risques du cloud

- Pouvez vous me donner des propriétés qui pourrait vous faire **ne pas** utiliser le cloud ?
 - Dans un certain contexte ?

IA dans le cloud

Cons

- Sécurité des données
 - Sécurité de l'hébergement
 - Sécurité du transfert
 - Sécurité de la consultation
- Dépendance à un tiers vs souveraineté
 - Si l'hébergeur ferme, se fait hacker, etc ?
- Connectivité
 - Si pas de connexion ou instable
 - Si objets trop volumineux vs contraintes de temps ou débit
- Coût
 - Coût de maintenance (équipe IT pour la gestion)
 - Coût d'achat ou de location
 - Coût d'utilisation (et surcoût de mauvaise utilisation)

— 2. Internalisation ou externalisation

Internalisation vs externalisation

Faut-il choisir?

- **SaaS : Externalisation de la connaissance algorithmique: consommer un produit « sur l'étagère »**
 - Gain de temps au déploiement : permet d'aller très vite et de livrer une première itération du produit
 - Évite l'éclatement du set de compétences
 - Permet de bénéficier de l'expertise et de la force de frappe d'un tiers beaucoup plus avancé
 - exemple OpenAI Api et ChatGpt
 - Externalise les contraintes liées au maintien, à la dérive et à l'amélioration continue de l'algorithme

MAIS

- Accroît l'effet black box : le fait d'être client d'un service ne vous donne pas nécessairement accès à des informations supplémentaires sur son fonctionnement, ses limites etc
- Risque de dépendance et donc de demande captive
 - Ex: OpenAI Api et ChatGpt
- Peut vite revenir cher en fonction de votre utilisation
- Confidentialité des données

Internalisation vs externalisation

Faut-il choisir?

- **IaaS ou Hosted : Externalisation de l'infrastructure**

- On garde la main sur l'algorithme et les choix techniques : on capitalise sur les ressources mises à disposition par les fournisseurs
 - Évite de bloquer des machines pendant des heures
 - Monitoring intégré : système d'alerte, tooling etc
- Evite l'achat de matériel pour quelques expérimentations: souplesse
- Evite la gestion et l'entretien du matériel

MAIS

- Coût de location
- Coût de maintenance
- Coût d'utilisation
- Coût de développement/déploiement dessus
- RGPD suivant la localisation géographique de vos serveurs et de vos données

Internalisation vs externalisation

Faut-il choisir?

- **SaaS : Externalisation du déploiement et de l'hébergement de l'application**
 - Gestion intelligente de la charge
 - Externalisation de contraintes : sécurité, disponibilité etc => pas de gestion de l'infrastructure
 - Partage de ressources simplifié
 - Mise à disposition d'outils et de support: monitoring
 - Accessibilité pour les utilisateurs

MAIS


- Dépendance forte au fournisseur sélectionné : risque de demande captive
- Peut vite revenir cher en fonction de votre utilisation
- Problématiques RGPD, gestion des données sensibles

READY ? FIGHT ... ?


Turnkey Platform
Ease and accessibility !



VS



Custom Approach
Let's be more specific !



VS


Time to market



Cost


Flexibility


Scalability



Integration


Control



5 TIPS FOR YOUR AI INDUSTRIALIZATION

The sixth : choose the right partner ! ;)



1

TALK TO
USERS !

« Understand their needs, their way of working, their expectations »

2

FRAMING
FIRST

«always define the need, the environment, the legal aspect, timing and define goals and KPI»

3

IT'S ALL
ABOUT DATA

« Data quality and supply at the heart of the process»

4

CHOOSE
RIGHT

« turnkey platform or custom approach : take into account all aspects to make the right technological choice »

5

ITERATIVE
SPIRIT

«experimentation, development, testing and deployment in a regular basis»

Humans & TECHNOLOGY
TO SCALE UP SUSTAINABLE PERFORMANCE